



Tecnológico de Monterrey

**Instituto Tecnológico y de Estudios Superiores de Monterrey
CAMPUS PUEBLA**

Analítica de datos y herramientas de inteligencia artificial I

Docente: Alfredo García Suárez

Ivanna Maldonado Cervantes - A01736844

Selección y limpieza de datos

17/09/2025

Selección y limpieza de datos

El objetivo de este preprocesamiento fue transformar los datos en bruto en el dataset de Airbnb Boston y convertirlo en un dataset confiable, estructurado y listo para el análisis. Se siguieron tres etapas principales: filtrado, imputación de valores nulos y tratamiento de valores atípicos, con el propósito de optimizar la calidad de la información y facilitar su interpretación en fases posteriores. Como no se conoce el objetivo del análisis, se tomó el dataset completo en cada fase para conservar la fidelidad de los datos y poder realizar la imputación de manera correcta.

Parte 1: Filtrado

En esta primera etapa se aplicaron filtros a las observaciones con el fin de visualizar diferentes datos de manera más clara y trabajar con subconjuntos manejables. Por ejemplo, se seleccionaron subconjuntos de filas, como aquellas que eran múltiplos de 4, y se extrajeron nombres de *hosts* específicos. Estos filtros permitieron observar tendencias puntuales y validar la estructura de los datos sin trabajar con todo el volumen desde un inicio. Asimismo, se eliminaron columnas que no aportaban al dominio del proyecto y se restablecieron los índices para mantener consistencia en la identificación de registros.

Parte 2: Tratamiento de Valores Nulos

Tras filtrar la base de datos, se evaluó la presencia de valores faltantes en cada variable. Se utilizó la función `isnull().sum()` para saber exactamente cuántos valores nulos se tenían en cada variable. Con base en este diagnóstico, se aplicaron las siguientes estrategias:

- Las variables con un porcentaje elevado de datos faltantes (más del 40%) y baja relevancia para el análisis fueron eliminadas.
- En los casos en que los datos eran importantes para el análisis, se aplicaron técnicas de imputación, por ejemplo:
 - Rellenar con un valor constante (ejemplo: -1) para diferenciar los casos imputados de los originales.
 - Sustituir con la media, mediana o moda según el tipo de variable (numérica o categórica).
- En variables de tipo string, los valores nulos se reemplazaron con el valor “Non specified” o “No data”.

Durante este proceso se priorizó conservar la mayor cantidad de información posible sin comprometer la validez del análisis, equilibrando la eliminación y la imputación de acuerdo con la naturaleza de cada variable.

Parte 3: Tratamiento de Valores Atípicos

Para detectar valores atípicos se utilizaron los métodos de desviación estándar y rango intercuartílico (IQR), complementado con gráficos de caja. Primeramente se reemplazaron los valores nulos del data frame por el método backfill. Después se obtienen los outliers y estos se convierten en nulos en el DataFrame. Una vez identificados estos valores nulos, se transformaron sustituyéndolos por la media.

Estas decisiones evitan que valores extremos afecten de manera desproporcionada los cálculos estadísticos y los modelos futuros, al mismo tiempo que se mantiene la representatividad de los datos reales.

Conclusión

El dataset final quedó optimizado a través de un proceso integral que incluyó filtrado, segmentación por clustering, imputación de valores nulos y tratamiento de valores atípicos. Este procedimiento permitió obtener un conjunto de datos depurado, coherente y representativo, adecuado para análisis avanzados y la toma de decisiones fundamentadas. En particular, el filtrado redujo la complejidad del dataset, la imputación aseguró la conservación de información relevante evitando vacíos que afectarían el análisis y el manejo de los atípicos eliminó distorsiones que podían sesgar los resultados, dejando así una base sólida y confiable para el desarrollo de modelos posteriores y para sustentar conclusiones con mayor precisión.