



**Instituto Tecnológico y de Estudios Superiores de Monterrey  
CAMPUS PUEBLA**

Analítica de datos y herramientas de inteligencia artificial I

Ivanna Maldonado Cervantes - A01736844

**Selección y limpieza de datos**

15/09/2025

## Selección y limpieza de datos

El objetivo de este preprocesamiento fue transformar los datos en bruto en un dataset confiable, estructurado y listo para análisis. Se siguieron tres etapas principales: filtrado, imputación de valores nulos y tratamiento de valores atípicos, con el propósito de optimizar la calidad de la información y facilitar su interpretación en fases posteriores.

### Parte 1: Filtrado

En esta etapa se seleccionaron las 50 variables más relevantes, eliminando el resto, esto para reducir la complejidad del dataset y enfocarlo al dominio del proyecto. Ya que no se contaba con información acerca de los objetivos del proyecto y el análisis, las variables se seleccionaron por criterio propio.

También se realizó un proceso de segmentación por clustering que me permitió agrupar observaciones que tenían características similares. Esta actividad me permitió identificar patrones naturales en los datos. Las gráficas de clustering tuvieron la particularidad de que los centroides se encontraban fuera de los clusters, esto a pesar de que el proceso de preparación fue el correcto.

Finalmente, se aplicaron filtros a las observaciones con el fin de conservar únicamente los registros de interés, obteniendo así un dataframe más manejable y enfocado. Estas acciones evitan ruido en el análisis, reducen redundancias y mejoran la eficiencia en el procesamiento de datos.

### Parte 2: Tratamiento de Valores Nulos

Primero se identificó la cantidad y proporción de valores faltantes en cada variable, usando la función `isnull().sum()` para saber exactamente cuántos valores nulos se tenían en cada variables. Con base en este diagnóstico, se aplicaron las siguientes estrategias:

- Las variables con un porcentaje elevado de datos faltantes (más del 40%) y baja relevancia para el análisis fueron eliminadas.
- En variables numéricas, los valores nulos se imputaron con medidas de tendencia central (media o mediana, según la distribución).
- En variables de tipo string, los valores nulos se reemplazaron con el valor “Non specified” o “No data”.

Durante este proceso se priorizó conservar la mayor cantidad de información posible sin comprometer la validez del análisis, equilibrando la eliminación y la imputación de acuerdo con la naturaleza de cada variable.

### **Parte 3: Tratamiento de Valores Atípicos**

Para detectar valores atípicos se utilizaron los métodos de desviación estándar y rango intercuartílico (IQR), complementado con gráficos de caja. Primeramente se reemplazan los valores nulos del data frame con el método backfill. Después se obtienen los outliers y estos se convierten en nulos en el DataFrame. Una vez identificados, se transformaron sustituyéndolos por la media.

Estas decisiones evitan que valores extremos afecten de manera desproporcionada los cálculos estadísticos y los modelos futuros, al tiempo que se mantiene la representatividad de los datos reales.

### **Conclusión**

El dataset final quedó optimizado, con variables relevantes, sin nulos críticos y con valores atípicos tratados adecuadamente. Este proceso asegura que se trabajará con datos consistentes, confiables y listos para ser empleados en los próximos análisis.